

PoV Multi-Agent

Atendimento coordenado por 3 agentes de IA, com MongoDB Atlas como plano de dados e de coordenação

Guia comercial e técnico + roteiro de apresentação ao cliente

1. O pitch — linguagem de negócio

O problema

Atendimento ao cliente hoje é ou 100% humano (caro, lento, não escala) ou chatbot genérico (não resolve, irrita e gera mais atrito do que valor). Empresas querem atendimento que resolve de verdade, sem depender de fila humana para tudo.

A solução

Um time de 8 agentes de IA especialistas — pedidos, produtos, suporte técnico, cobrança, garantia, fidelidade, logística e um orquestrador que decide quem atende — trabalhando em equipe, como um time de atendimento real. Cada agente sabe sua função; quando um não resolve sozinho, passa o bastão para o colega certo, sem o cliente repetir a história do zero. Uma única mensagem do cliente pode percorrer até 4 agentes em sequência num só turno.

Por que isso vende sozinho, ao vivo

- **A troca de bastão acontece na tela.** Cliente reclama de produto com defeito → agente de suporte diagnostica → transfere para o agente de produto, que já recomenda uma alternativa mais barata, sozinho, sem intervenção humana.
- **O sistema lembra do cliente.** Se ele demonstrou se importar com preço numa conversa, dias depois — em assunto totalmente diferente — a IA já prioriza opções mais baratas, sem perguntar de novo.
- **Configuração sem deploy.** Trocar a personalidade, o modelo ou a permissão de um agente é editar um documento. Desligar um agente em produção e ver o sistema se adaptar sozinho, na hora, é um momento de choque positivo em qualquer demo.
- **Isolamento de dado por identidade.** Nenhum cliente nunca vê dado de outro — segurança por identidade, não por sorte.

Onde o MongoDB brilha (mensagem de negócio)

Normalmente, coordenar múltiplos agentes de IA é a parte cara e frágil de qualquer projeto — filas externas, orquestradores adicionais, código difícil de mudar. Aqui, essa coordenação inteira — quem atendeu, para quem passou, por quê, o que a IA lembra do cliente — vive dentro do mesmo banco de dados que já guarda pedido, fatura e produto. Uma única plataforma, sem precisar de quatro ferramentas diferentes: implantação mais rápida, manutenção mais barata, e um painel de auditoria que já vem de graça.

2. O pitch — linguagem técnica

Arquitetura

8 agentes (orchestrator, order_agent, product_agent, support_agent, billing_agent, warranty_agent, loyalty_agent, logistics_agent) coordenados por roteamento em 2 níveis: regra determinística barata (regex/keywords em ai_brain.routing_rules) resolve o caso óbvio sem custo de LLM; caso ambíguo vai para o orquestrador (Claude Haiku), que classifica a intenção e nunca responde direto ao cliente. Uma cadeia pode chegar a 4 saltos num turno (ex.: suporte diagnostica → produto recomenda → pedido efetiva a troca → fatura confirma o impacto), e um par de agentes independentes (pedido + fatura) pode ser despachado em paralelo quando a pergunta é composta, em vez de sequencial.

Os 8 agentes

Agente	Função	Escreve?
orchestrator	Classifica intenção, roteia, nunca responde ao cliente	Não
order_agent	Status de pedido, troca/reembolso	Sim — só status, valores aprovados
product_agent	Recomendação via vector search, ponderada por relevância+nota+estoque	Não
support_agent	Diagnóstico via RAG híbrido; abre chamado real quando não resolve	Sim — chamados de suporte
billing_agent	Consulta de fatura	Não
warranty_agent	Cobertura de garantia por categoria + data de compra	Não
loyalty_agent	Saldo de pontos, tier, resgate real de recompensa	Sim — dedução de pontos, catálogo fixo
logistics_agent	Transportadora, rastreio, previsão; sinaliza reagendamento	Sim — flag de reagendamento

MongoDB como plano de coordenação, não só de dados

Collection	Papel
ai_brain.agent_registry	Persona, modelo, fallback, tools e budget por agente — editável em runtime, sem deploy. 8 agentes
agent_handoffs / agent_traces	Cada transferência entre agentes é um documento auditável, com Change Stream em tempo real. "O
customer_memory	Memória de longo prazo com supersessão transacional por (customer_key, fact_type). Fato extraído
semantic_cache	Isolado por agent + area + customer_key + question_norm — hit de um cliente nunca vaza para outro
products_catalog / kb_articles	VectorSearch com Automated Embedding (voyage-4); ranking ponderado (relevância + rating + esto
support_tickets / redemptions	Escritas reais dos novos agentes: chamado de suporte aberto e resgate de pontos confirmado — nã
eval_runs	Histórico de qualidade (GoalSuccessRate) de um harness de eval que roda contra o servidor real e g

Tempo real e segurança

- **Change Streams:** GET /api/events/stream (SSE) tail em agent_handoffs, filtrado por ownership; fallback poll em modo sem Atlas.
- **Ownership:** customer_key só sai do claim JWT sub, nunca do payload — todo filtro de pedido/fatura é reconstruído do zero.
- **Escrita restrita:** único write do sistema é order_agent fazendo \$set.status contra allowlist.

- **Guardrails:** mascaramento de PII antes de LLM/memória/log, guardrail de entrada e saída.
- **Resiliência:** budget de tokens por agente + global, deadline de 120s, retry só em erro transitório, fallback de modelo por agente.

Resultado: 9 padrões de arquitetura de agente (roteamento, handoff multi-hop, fan-out paralelo, memória, cache, segurança, observabilidade, retrieval híbrido, tempo real) sobre uma única collection store — sem Kafka, sem Redis, sem orquestrador externo.


3. Roteiro de apresentação ao cliente

Passo a passo com print de tela real da aplicação e o porquê de cada clique. Use multiagent no terminal para abrir a PoV antes de começar.

Passo 0 — Abrir a aplicação

O que fazer: Rode python warmup.py antes da reunião pra pré-aquecer o cache com as perguntas do roteiro (custo real, uma vez, honesto — sem fingir consumo). Depois abra a PoV: o painel lateral já mostra os 8 agentes e o indicador “ao vivo” pulsando — prova que o Change Stream do MongoDB já está conectado antes da primeira pergunta.

O que isso prova: Passa a mensagem de que o sistema já está “vivo” e observável, e que o primeiro clique do cliente não vai esperar uma cadeia de LLM fria.



Passo 1 — Cadeia completa: 4 agentes num turno só — o momento-chave da demo

O que fazer: Clique no atalho “meu pedido PED-1001 chegou com defeito, quero um parecido mais barato, e quero trocar — isso mexe na minha fatura?”. Aponte a esteira “agentes em ação”: suporte diagnostica → produto recomenda mais barato → pedido efetiva a troca (única escrita restrita do sistema) → fatura confirma o impacto. Cada seta é um documento em agent_handoffs.

O que isso prova: Mostra 4 agentes especializados colaborando de forma autônoma numa única mensagem, cada handoff auditável como documento — não uma caixa preta. Aponte também o painel “coleções em ação”: cada operação mostra a collection e o tipo (leitura, escrita, \$vectorSearch, BM25+RRF).

POV · ARQUITETURA MULTI-AGENTE

A colaboração é uma query.

Cada decisão, ferramenta e handoff deixa um documento consultável no MongoDB.

TURNO ATUAL
conv-536be5a72aeb
billing_agent
+ nova conversa

AGENTES EM AÇÃO

Supporte chamou → Produtos chamou → Pedidos chamou → Cobrança

COLEÇÕES EM AÇÃO NESTE TURNO

guardrail_denylist
LEITURA

customer_memory
ESCRITA

ai_brain.agent_registry
LEITURA

semantic_cache
LEITURA

kb_articles
BM25 + VETOR (RRF)

agent_handoffs
ESCRITA ESCRITA ESCRITA

products_catalog
\$VECTORSEARCH

orders
ESCRITA

invoices
LEITURA

8
AGENTES ATIVOS

3
HANDOFFS NO TURNO

orchestrator
ORIGEM DA ROTA

2802
TOKENS ESTIMADOS

ÚLTIMO HANDOFF · AGENT_HANDOFFS

CHANGE STREAM

order_agent → billing_agent

cliente quer saber o impacto da troca/reembolso na fatura

CANAL DO CLIENTE

RAIO-X DO TURNO

12 EVENTOS

INSPECTOR MONGODB

VOCE

01

GUARDRAIL

Guardrail de entrada

MongoDB guardrail_denylist

02

MEMÓRIA

Fato extraído do turno e persistido (supersessão)

MongoDB customer_memory

Filtro / consulta

Resultado

03

AGENTE support_agent

Roteamento inicial

MongoDB ai_brain.agent_registry

Filtro / consulta

Resultado

04

CACHE support_agent

Cache semântico do agente

MongoDB semantic_cache

Filtro / consulta

Resultado

Chat

Agentes

Guardrails

Métricas

IDENTIOADE

ana

AO VIVO

memory-demo · ok

enviado em 14 de julho de 2026.

O Fone Pulse X saiu para entrega nessa data. Para rastrear a localização em tempo real ou prazo de entrega, consulte a transportadora através do código de rastreamento que você recebeu por email.

VOCE

Digite sua solicitação... (Enter envia, Shift+Enter quebra linha)

Enviar turno

meu pedido PED-1001 chegou co... onde está meu pedido PED

Supporte support_agent EM USO NESTE TURNO

Cobrança billing_agent EM USO NESTE TURNO

Garantia warranty_agent claude-haiku-4-5

Fidelidade loyalty_agent claude-haiku-4-5

Logística logistics_agent claude-haiku-4-5

MongoDB Atlas

multi_agent_poc + ai_brain

Ana Souza

Passo 2 — 8 agentes reais, sem enfeite

O que fazer: Vá para a aba Agentes. Mostre que são 8 cartões, todos com modelo, persona e budget próprios — nenhum documento dormente só pra inflar número. Com o modo admin ligado, desative o product_agent no switch e repita a pergunta do Passo 1: o orquestrador usa fallback sem reiniciar nada.

O que isso prova: Prova que o “time de agentes” é um documento editável — ajustar comportamento em produção não exige deploy, só um update — e que a contagem de agentes é honesta (se diz 8, são 8 respondendo de verdade).

AI_BRAIN.AGENT_REGISTRY

O time de agentes é uma collection.

Modelo, persona, ferramentas e budget mudam por documento — sem deploy. 8 agentes reais, todos respondem de fato — nenhum documento de enfeite.

MODDO ADMIN (DESLIGADO)

Orquestrador

orchestrator

Classifique, roteie e consolide. Nunca responda diretamente ao cliente.

modelo

claude-haiku-4-5

budget

700 tok

tools

route, consolidate

Pedidos

order_agent

Resolva status, troca e reembolso somente para pedidos do titular autenticado.

modelo

claude-haiku-4-5

budget

1000 tok

tools

read_order, update_order_status

Produtos

product_agent

Recomende produtos relevantes usando somente resultados do catálogo.

modelo

claude-sonnet-4-5

budget

1400 tok

tools

vector_search_products

Suporte

support_agent

Cobrança

billing_agent

Garantia

warranty_agent

MongoDB Agent Control Plane

ChatAgentesGuardrailsMétricasIDENTIDADEanaAD VIVOmemory-demo · ok

modelo

claude-sonnet-4-5

budget

1400 tok

tools

hybrid_search_kb, handoff

modelo

claude-haiku-4-5

budget

900 tok

tools

read_invoice

modelo

claude-haiku-4-5

budget

900 tok

tools

read_warranty_policy, read_order

L

Fidelidade

loyalty_agent

Informe saldo de pontos, tier e benefícios do programa de fidelidade do titular autenticado, em modo somente leitura.

modelo

claude-haiku-4-5

budget

900 tok

tools

read_loyalty_account

L

Logística

logistics_agent

Informe transportadora, código de rastreio, localização atual e previsão de entrega do pedido do titular autenticado, em modo somente leitura.

modelo

claude-haiku-4-5

budget

900 tok

tools

read_shipment

MongoDB Atlasmulti_agent_poc + ai_brainAna Souza

Passos complementares (sem necessidade de print): troque a identidade no seletor do topo — cada uma tem perguntas próprias que batem em dados reais e diferentes — e repita uma pergunta de pedido de outro cliente para provar isolamento; mostre um prompt de **guardrail** (política de negócio ou jailbreak) populando a aba Guardrails ao vivo; feche em **Métricas** mostrando tokens, cache hits e latência por agente, e o histórico do eval harness (modo admin).